# 冼炬恩



13877442036 xianjuen233@163.com
在读 全栈开发 北京

## 教育经历

**北京邮电大学** 计算机科学与技术 本科 2023-09 ~ 2027-07
全日制 计算机学院 北京
主修高等数学、数据结构、计算机网络、数据库、机器学习等计算机科学核心课程，荣誉与证书：大学生数学奥林匹克竞赛国家级二等奖,北京邮电大学鸿雁杯三等奖，大学生创新创业大赛国家级项目认定，CET4/6, GPA：3.51/4，专业排名：146/374（39%）。

## 专业技能

- 熟练使用 Python + LangChain / LangGraph + FastAPI 构建 Agent 应用，掌握多 Agent 编排、Checkpoint 状态恢复、人工干预（Human-in-the-loop）等生产级模式；
- 掌握 Function Calling / Tool Calling 机制，有工具注册表、分层路由、按需绑定 Schema、高风险工具权限校验的落地经验；
- 掌握RAG全链路：文档分块、Embedding、向量检索、混合检索与重排序，熟悉 RAG 评测体系；
- 熟悉 Git、Maven 等协作工具，熟练使用 Codex、OpenCode 等 AI 编程工具提效。

## 项目经历

**ANAVideoAI——长视频内容理解 Video Agent 平台** 2025-09 ~ 2025-12
全栈开发和Agent开发 https://github.com/xje233/ANAVideo-AI.git
基于SpringBoot、MySQL、Redis、RocketMQ、MyBatis-Plus、MinIO、LangChain4j、Vue，面向课程回放、会议录屏这类长耗时、高资源消耗、外部调用成本敏感的场景，设计并实现从**分片上传、多模态感知、证据检索到受控 Agent 分析**的全链路后端，目标是把长视频转化为可检索、可追溯、可继续追问的证据资产。

- **结果校验：**设计 **Planner–Executor–Critic** 受控循环：目标拆成 1~5 个可验证任务；每条结论**强制绑定 claim + 时间戳 + 来源 + 原文**，由确定性程序**校验时间戳**是否命中真实片段、原文能否在 ASR/OCR 文本中匹配；Critic 返回"遗漏任务 / 无证据结论 / 指定时间范围"三类**结构化反馈**，程序据此重规划或定向补证后重执行，使第二轮上下文真正改变；循环由 2 轮 + 120s + 5 万 Token 三类预算强制终止。
- **断网重传：**前端按 **5MB 分片**并发上传（上限 410 片、约 2GB），服务端以 uploadId 管理归属并**写入 Redis Hash、TTL 1 天**；分片先落 **MinIO** 再记 **Redis Set**，恢复时取集合差集只补缺失序号；合并按序拼接并流式计算内容 MD5，**Redisson 锁 + completedKey** 保证重复合并幂等。
- **并发控制、幂等防重和失败兜底：RocketMQ** 承载任务入口，Web 层只做校验、限流、投递后返回 202；幂等键取「内容指纹 + 目标摘要」，入口 SETNX 拦重复提交，消费端 Redisson 锁控 MQ 重投与多实例并发；**Checkpoint** 以 MySQL 为恢复真源、Redis 为 7 天热缓存，按阶段恢复；失败重投 3 次后落失败表并投递独立失败主题。
- **“成本 + 容量”双重防护：**MQ 投递前用 Redisson RRateLimiter 做**用户级 5 次/分 + 全局 30 次/分**双维度限流，Redis 异常时 fail-closed；ASR / LLM 等第三方调用最多 3 次**指数退避重试。**

**Workflow工作流平台** 2026-02 ~ 2026-04
Agent开发和后端开发 https://github.com/xje233/AI_Agent_Workflow.git
基于Python + LangGraph + LangChain + FastAPI +React+ pgvector + Redis，针对企业复杂业务中单 Agent 难以处理多步骤任务、缺乏状态恢复及人工干预的问题，设计并实现一套生产级多Agent工作流系统。构建支持多轮对话、RAG 知识库检索、多工具协作以及复杂工作流自动执行的自动化平台。

- **Agent 首 Token 性能优化**：针对简单问答仍走完整 Agent、携带无关工具定义的问题，增加**无工具直连**路径。后端平均 **TTFT 从 1641.77ms 降至 1102.12ms（32.9%），P95 从 2209.01ms 降至 1515.90ms（31.4%），标准差下降 44.2%。。**
- **分层工具路由**：针对工具全量暴露导致 Schema 占用上下文、相似工具易误选、高风险工具有副作用却无门槛的问题，把**「按需加载」升级为四层路由——工具注册表卡片→ 确定性过滤→ 业务域粗分→ 词法 IDF 与向量混合检索 Top-K**，仅把候选工具的完整 Schema 绑定给模型；高风险工具默认不进候选，向量层不可用时进程内降级为纯词法，执行期再校验工具名是否落在候选集内拦截越权调用。在 28 条路由用例上 **recall@3 / exact_match@3 / precision@3 均为 1.0**，无工具拒选准确率 1.0，越权暴露率 0.0，高风险副作用拦截率 1.0，平均候选 0.96 个，路由 P50 耗时 116.07ms。
- **性能与回归观测**：使用 **RAGEval自动构建**工程等相关领域的测试集以及 **公开测试集FlashRAG**，中英双 语语料，**量化完整性/幻觉/不相关性**三个指标，提供性能观测和优化思路。 右，**MRR 达到 0.83 左右。**